Semana 8, segunda parte: del dataset al modelo (estadísticas de YouTube)

Curso Procesamiento de Lenguaje Natural · Hoja de resultados

1. Propósito, entrega y forma de trabajo

Esta es la segunda parte del proyecto Estadísticas de YouTube. En la primera parte (semana 7) el equipo preparó y analizó los datos; en esta, entrena y compara modelos de Procesamiento de Lenguaje Natural que predicen el desempeño de un video a partir de sus comentarios. Con base en la información del dataset, el equipo responde con sus propios resultados siete preguntas: qué análisis estadísticos se pueden hacer, cuál fue el modelo seleccionado, cuál fue su desempeño y bajo qué métricas, cuántos modelos se probaron, qué herramientas se usaron para determinar el modelo, si es suficiente un solo modelo y qué variables se seleccionaron para predecir.

El trabajo se hace en el notebook 02_modelos.ipynb del repositorio del taller, que ya contiene el código. El equipo no programa: en cada sección toma decisiones en formularios (casillas, listas y deslizadores), ejecuta la celda e interpreta los resultados. Este documento es la **hoja de resultados**: en cada sección se registran las cifras obtenidas y su interpretación.

Aspecto	Detalle
Curso	Procesamiento de Lenguaje Natural
Entrega	Al finalizar la semana 8
Duración de la práctica	2 horas
Notebook	notebooks/02_modelos.ipynb (se abre en Colab con el enlace del README)
Datos	Dataset YouTube Statistics de Kaggle (advaypatil/youtube-statistics) procesado con el pipeline de la primera parte; opcionalmente, la extracción de la YouTube Data API
Requisitos	Los mismos de la primera parte: secretos de Kaggle en Colab y la carpeta del equipo en Google Drive

Qué se predice. Por defecto, la variable objetivo que el equipo eligió en la primera parte (engagement, log_views, log_likes o perf_class). Las variables predictoras salen del contexto del video y, sobre todo, del texto de sus comentarios.

Distribución del tiempo

Sección del notebook	Tiempo	Sección de esta hoja
Celdas 1 y 2 y sección 3: preparar el entorno y cargar la tabla de features	15 min	1
4. Análisis estadísticos	20 min	2
5. Selección de variables	20 min	3
6. Entrenar y comparar modelos	25 min	4
7. Desempeño y comparación estadística	15 min	5
8. Modelo seleccionado	15 min	6
9. ¿Es suficiente un solo modelo? y 10. Resumen	10 min	7 y 8

Registro del equipo

Campo	Respuesta del equipo
Integrantes	
Fuente de datos usada (kaggle o api) y número de videos	
Variable objetivo y tipo de problema (regresión o clasificación)	

2. ¿Qué análisis estadísticos se pueden hacer?

Conceptos clave

- **Análisis de la primera parte:** el pipeline ya calculó nueve análisis estadísticos (archivo stats_report), con su pregunta, prueba y conclusión; el notebook los reúne en una tabla.
- **Distribución de la variable objetivo:** forma y asimetría en regresión, o balance de clases en clasificación. Un objetivo muy desbalanceado hace engañosas métricas como la *accuracy*.
- **Correlación de Spearman con corrección de Benjamini-Hochberg:** mide la relación monótona entre cada feature de los comentarios y el objetivo. Al probar muchas variables a la vez, algunas parecen significativas por azar; la corrección ajusta los valores p para controlar ese riesgo.
- **Comparación estadística de modelos** (sección 7 del notebook): la prueba de Wilcoxon y el intervalo de confianza *bootstrap* indican si la diferencia entre modelos es sólida o podría deberse al azar.

En el notebook

1. Ejecutar las celdas 1 y 2 y la sección 3, eligiendo la fuente de datos (kaggle o api) y la variable objetivo.
2. Ejecutar la sección 4 y revisar la tabla de análisis de la primera parte, la distribución del objetivo y las correlaciones.

Resultados del equipo

Análisis	Resultado obtenido (cifras)	Interpretación
Dos análisis de la primera parte que el equipo considera más relevantes		
Distribución del objetivo (media, mediana, asimetría o proporción por clase)		
Features de comentarios con correlación significativa después de la corrección		
Feature con la correlación más fuerte (rho y signo)		

Interpretación del equipo

Pregunta	Respuesta del equipo
¿Qué dicen estos análisis sobre la posibilidad de predecir el desempeño a partir de los comentarios?	
¿Qué otro análisis estadístico sobre el texto propondría el equipo (por ejemplo, sobre emojis, idioma o longitud)?	

Para profundizar: ¿qué problema resuelve la corrección por comparaciones múltiples y en qué se diferencia el método de Benjamini-Hochberg del de Bonferroni?

3. ¿Qué variables se seleccionaron para predecir?

Conceptos clave

- **Bloques de variables:** *contexto* (keyword, antigüedad, día y hora de publicación, características del título); *features de comentarios* (sentimiento medio y ponderado, polarización, porcentaje positivo y negativo, longitud, diversidad léxica, preguntas, exclamaciones y emojis); y *texto TF-IDF* (los n-gramas del texto de los comentarios).
- **TF-IDF:** representa cada video por las palabras de sus comentarios, ponderadas por su frecuencia en el video y su rareza en el conjunto. Los parámetros clave son los n-gramas (palabras sueltas o pares), el tamaño máximo del vocabulario y la frecuencia mínima de un término.
- **Fuga de información:** las vistas, los *likes* y el número de comentarios del video no se usan como predictores, porque con ellos se calcula la variable objetivo.
- **Aporte del texto:** comparar el modelo con y sin texto muestra si los comentarios realmente ayudan a predecir.

En el notebook

1. En la sección 5, marcar los bloques de variables y ajustar los parámetros del TF-IDF.
2. Revisar el tamaño del vocabulario y los términos más asociados con el objetivo.
3. Opcional: repetir las secciones 5 y 6 con otra configuración (por ejemplo, solo texto o sin texto) y comparar.

Resultados del equipo

Campo	Respuesta del equipo
Bloques de variables seleccionados	
Parámetros del TF-IDF (n-gramas, máximo de términos, frecuencia mínima) y tamaño del vocabulario	
Términos más asociados con valores altos y bajos del objetivo	
Si se hizo la prueba opcional: configuración alternativa y efecto en el error	

Interpretación del equipo

Pregunta	Respuesta del equipo
¿Los términos más asociados tienen sentido lingüístico o reflejan ruido (nombres propios, temas de una sola keyword)?	
¿Qué otra representación del texto probaría el equipo (*embeddings*, modelos preentrenados, lematización) y por qué?	

Para profundizar: ¿qué diferencias hay entre la bolsa de palabras, TF-IDF y los *embeddings* de oraciones, y cuándo conviene cada uno?

4. ¿Cuántos modelos se probaron y con qué herramientas?

Conceptos clave

- **Modelos disponibles:** base (promedio o clase más frecuente), lineal regularizado (Ridge o regresión logística), SVM lineal, bosque aleatorio y *gradient boosting*. Los modelos lineales trabajan directamente con el TF-IDF; para los de árboles, el texto se reduce primero con análisis semántico latente (TruncatedSVD).
- **Partición por video:** el 20 % de los videos se reserva para la prueba final; sobre el 80 % restante se hace una validación cruzada de 5 particiones para comparar modelos. Nunca se mezclan comentarios de un mismo video entre entrenamiento y prueba.
- **Herramientas:** Google Colab y Google Drive (entorno y almacenamiento), Python, pandas, SciPy, scikit-learn (TfidfVectorizer, ColumnTransformer, modelos, cross_validate y métricas), Matplotlib y el pipeline ytnlp del taller.

En el notebook

1. En la sección 6, marcar los modelos que se van a comparar (se recomienda incluir la base y al menos tres modelos más).
2. Ejecutar la celda; la tabla muestra la métrica en validación cruzada, su desviación, las métricas en prueba y el tiempo de cada modelo.

Resultados del equipo

Campo	Respuesta del equipo
Número de modelos probados y cuáles	
Configuraciones adicionales probadas (otros bloques de variables u otros parámetros del TF-IDF)	
Herramientas usadas para determinar el modelo	
Modelo más rápido y más lento (segundos)	

Interpretación del equipo

Pregunta	Respuesta del equipo
¿Por qué los modelos lineales suelen funcionar bien con representaciones TF-IDF?	
¿Qué modelo adicional probaría el equipo (por ejemplo, un transformador preentrenado ajustado al dataset) y qué costo tendría?	

Para profundizar: ¿qué es el análisis semántico latente (LSA) y por qué reduce la dimensionalidad del texto?

5. ¿Cuál fue el desempeño y bajo qué métricas?

Conceptos clave

- **Métricas de regresión** (engagement, log_views, log_likes): MAE (error absoluto medio en escala logarítmica; menor es mejor), RMSE (penaliza los errores grandes), R^2 (proporción de la variabilidad explicada; 0 equivale a predecir el promedio) y Spearman (si el modelo ordena bien los videos de menor a mayor desempeño).
- **Métricas de clasificación** (perf_class): *accuracy* (proporción de aciertos) y F1 macro (promedio del F1 de cada clase, que no se deja engañar por clases desbalanceadas).
- **Validación frente a prueba:** los modelos se comparan con la validación cruzada; la prueba confirma el desempeño esperado con videos nuevos.
- **Solidez de la diferencia:** la prueba de Wilcoxon compara dos modelos partición por partición, y el intervalo de confianza *bootstrap* del 95 % indica cuánto podría variar la métrica con otros videos de prueba.

En el notebook

Copiar de la tabla de la sección 6 las métricas de cada modelo y ejecutar la sección 7 para obtener la comparación estadística y el intervalo de confianza.

Resultados del equipo

Modelo	Métrica en validación cruzada (MAE o F1 macro)	MAE o *accuracy* en prueba	RMSE o F1 macro en prueba	R^2 en prueba (regresión)
Base				

Modelo	Métrica en validación cruzada (MAE o F1 macro)	MAE o *accuracy* en prueba	RMSE o F1 macro en prueba	R^2 en prueba (regresión)

Campo	Respuesta del equipo
Prueba de Wilcoxon: modelos comparados, diferencia promedio y valor p	
Intervalo de confianza *bootstrap* del 95 % del mejor modelo	

Interpretación del equipo

Pregunta	Respuesta del equipo
¿Qué modelos superaron a la base y la diferencia es estadísticamente sólida?	
¿El desempeño es suficiente para usar el modelo en una decisión real (por ejemplo, priorizar qué videos promocionar)? Justificar	

Para profundizar: ¿qué métrica conviene reportar cuando las clases están desbalanceadas y por qué la *accuracy* puede ser engañosa?

6. ¿Cuál fue el modelo seleccionado?

Conceptos clave

- **Criterios de selección:** mejor métrica en validación cruzada, estabilidad entre particiones, diferencia estadísticamente sólida frente a los demás, tiempo de entrenamiento y facilidad de explicar las predicciones. Entre modelos con desempeño parecido se prefiere el más simple.
- **Interpretación del modelo:** en los modelos lineales, los coeficientes del TF-IDF muestran qué palabras empujan la predicción hacia arriba o hacia abajo; la importancia por permutación mide cuánto empeora el modelo al desordenar cada variable (incluido el texto completo).

- **Análisis de errores:** la matriz de confusión (clasificación), la gráfica de predicción frente a valor real (regresión) y el error por keyword muestran dónde falla el modelo.

En el notebook

1. En la sección 8, elegir en la lista el modelo que el equipo considera mejor.
2. Ejecutar la celda y revisar los términos con más peso, la importancia de las variables, la matriz de confusión o la gráfica de predicción y el error por keyword.

Resultados del equipo

Campo	Respuesta del equipo
Modelo seleccionado	
Métricas en prueba del modelo seleccionado	
Criterios usados para seleccionarlo	
Variables o términos más importantes	
Keywords con mejor y peor desempeño	

Interpretación del equipo

Pregunta	Respuesta del equipo
¿Las palabras con más peso tienen sentido para explicar el desempeño de un video? ¿Hay señales de sesgo o de ruido?	

Pregunta	Respuesta del equipo
¿Cómo explicaría el equipo el modelo seleccionado a un creador de contenido, en un párrafo y sin términos técnicos?	

Para profundizar: ¿qué técnicas de explicabilidad existen para modelos de PLN (coeficientes, importancia por permutación, LIME, valores SHAP) y qué aporta cada una?

7. ¿Es suficiente un solo modelo?

Conceptos clave

- **Ensamble:** combina las predicciones de varios modelos (promedio en regresión, voto por mayoría en clasificación). Si mejora al mejor modelo individual, los modelos se complementan.
- **Aporte del texto:** el notebook entrena el mejor modelo sin el bloque TF-IDF; la diferencia muestra cuánto aporta el PLN frente a las variables de contexto y las features numéricas.
- **Error por segmentos:** si el desempeño cambia mucho entre keywords o idiomas, pueden necesitarse modelos especializados.
- **Un modelo por pregunta:** predecir el desempeño de un video, clasificar el sentimiento de cada comentario o detectar comentarios tóxicos son tareas distintas que suelen requerir modelos distintos, a veces encadenados (por ejemplo, un clasificador de sentimiento cuyas salidas alimentan el modelo de desempeño).

En el notebook

Ejecutar la sección 9, que compara el mejor modelo individual con el ensamble y con el mismo modelo sin texto, y la sección 10, que genera el resumen.

Resultados del equipo

Campo	Respuesta del equipo
Métricas del mejor modelo individual	
Métricas del ensamble	

Campo	Respuesta del equipo
Métricas del mejor modelo sin texto TF-IDF	

Interpretación del equipo

Pregunta	Respuesta del equipo
¿Es suficiente un solo modelo? Tomar posición y sustentarla con los resultados	
¿Aportan los comentarios a la predicción? ¿Cuánto?	
¿Qué modelo complementario propondría el equipo y para qué tarea?	

Para profundizar: ¿qué es la deriva de datos (*data drift*) en modelos de PLN y por qué el lenguaje de los comentarios de YouTube cambia con el tiempo?

8. Síntesis para la entrega de la semana 8

Con apoyo del resumen que genera la sección 10 del notebook, el equipo responde en pocas líneas cada pregunta, basado en la información del dataset.

Pregunta	Respuesta del equipo
¿Qué análisis estadísticos podemos hacer?	
¿Cuál fue el modelo seleccionado?	

Pregunta	Respuesta del equipo
¿Cuál fue su desempeño y bajo qué métricas?	
¿Cuántos modelos se probaron?	
¿Qué herramientas se usaron para determinar el modelo?	
¿Es suficiente un solo modelo?	
¿Qué variables se seleccionaron para predecir?	

Qué se entrega al finalizar la semana 8: esta hoja de resultados diligenciada y la copia del notebook 02_modelos ejecutada con datos reales, compartida con el docente como *Lector* o *Comentador*.

9. Fuentes de consulta

Fuente	Acceso
Patil, A. *YouTube Statistics* (dataset). Kaggle	https://www.kaggle.com/datasets/advaypatil/youtube-statistics
Jurafsky, D. y Martin, J. H. *Speech and Language Processing*, 3.ª ed. (borrador en línea)	https://web.stanford.edu/~jurafsky/slp3/
Manning, C., Raghavan, P. y Schütze, H. (2008). *Introduction to Information Retrieval* (capítulos sobre TF-IDF y clasificación de texto). Cambridge University Press	https://nlp.stanford.edu/IR-book/
scikit-learn: trabajo con datos de texto, validación cruzada y métricas	https://scikit-learn.org/stable/modules/feature_extraction.html#text-feature-extraction · https://scikit-learn.org/stable/modules/cross_validation.html · https://scikit-learn.org/stable/modules/model_evaluation.html

Fuente	Acceso
SciPy: pruebas estadísticas	https://docs.scipy.org/doc/scipy/reference/stats.html
Demšar, J. (2006). Statistical Comparisons of Classifiers over Multiple Data Sets. *Journal of Machine Learning Research*, 7	https://jmlr.org/papers/v7/demsar06a.html
Molnar, C. *Interpretable Machine Learning*	https://christophm.github.io/interpretable-ml-book/